

UCUENCA

UNIVERSIDAD DE CUENCA

DEET — Maestría en Ciencias de la Ingeniería Eléctrica

Comparación de Enfoques K-Means: Exoesqueleto vs. Mantenimiento Robótico Sintético

Ing. Jean Carlo Aucapina

Ing. Henry Maldonado

2026-06-03

1. Contexto General

Este documento compara dos aplicaciones independientes del algoritmo K-Means implementadas en Julia, ambas desarrolladas en el marco del curso de Redes Complejas. Aunque comparten el mismo núcleo algorítmico, difieren en el origen de los datos, el dominio de aplicación y la interpretación de los clusters resultantes.

Dimensión	Proyecto A — Exoesqueleto (Henry)	Proyecto B — Robótica Sintética (Jean)
Dominio	Biomecánica / robótica médica	Mantenimiento predictivo industrial
Objetivo	Agrupar mediciones de actuadores de exoesqueleto por perfil de operación	Clasificar actuadores robóticos por estado de degradación
Datos	Reales — telemetría de sensores de exoesqueleto (mediciones diarias)	Sintéticos — inventario de 120 actuadores generado por <code>synthesis.jl</code>
Unidad de análisis	Medición diaria de un actuador (filas del log)	Actuador individual (pieza física)
Salida del modelo	Mapa medición → perfil de operación (4 clusters)	Mapa pieza → estado (Programado / Urgente / Reemplazo)
Carpeta	<code>Kmeans_Robot_Henry/</code>	<code>Kmeans_Robot_Jean/Robotica_kmeans_sinte</code>

2. Metodología — Proyecto A: Exoesqueleto (Henry)

2.1 Descripción del Problema

Un exoesqueleto robótico contiene múltiples actuadores (cadera, rodilla, tobillo, etc.) cuyo comportamiento varía según la sesión de rehabilitación, el paciente y el desgaste acumulado. El Proyecto A aplica K-Means sobre el **log histórico de mediciones diarias** para descubrir automáticamente patrones de operación: ¿qué grupos de mediciones comparten el mismo perfil de carga, temperatura y desgaste?

A diferencia del Proyecto B, aquí no se parte de etiquetas conocidas de estado — los clusters emergen exclusivamente de los datos de los sensores.

Dataset: 663 mediciones diarias de actuadores de exoesqueleto, año 2024.

2.2 Features — 9 Variables de Telemetría

Feature	Descripción
<code>tiempo_uso_acumulado_h</code>	Horas acumuladas de uso del actuador

Feature	Descripción
ciclos_activacion_M	Millones de ciclos de activación completados
numero_reparaciones	Reparaciones realizadas hasta la fecha
fallos_temporales	Fallos temporales registrados
temp_operacional_promedio_C	Temperatura promedio durante operación (°C)
temp_maxima_alcanzada_C	Temperatura máxima alcanzada (°C)
dias_ultima_calibracion	Días desde la última calibración
dias_ultimo_servicio	Días desde el último servicio técnico
numero_logs_error	Entradas de error en el log del sistema

No existe feature dominante con peso explícito — todas las variables contribuyen en igualdad de condiciones. La señal de agrupamiento emerge de la correlación natural entre temperatura, ciclos y errores de log.

2.3 Selección de K

Se evaluaron K [2, 9] usando silhouette + Davies-Bouldin score.

K	Inercia	Silhouette	Davies-Bouldin	Seleccionado
2	2 866.4	0.3087	1.305	
3	2 268.8	0.2727	1.270	
4	1 911.5	0.2659	1.229	
5	1 599.8	0.2749	1.083	
6	1 429.4	0.2723	1.075	
7	1 292.3	0.2617	1.092	
8	1 180.8	0.2704	1.031	
9	1 096.6	0.2541	1.040	

$K^* = 4$ — elección basada en combinación de métricas. El silhouette global es bajo (~ 0.27) porque los datos son reales y continuos: no existen grupos perfectamente separados, sino transiciones graduales entre perfiles de operación.

2.4 Resultados de Clustering

Cluster	Perfil inferido	Mediciones	Silhouette aprox.
C0	Operación normal — baja carga, baja temperatura	alto	~0.31
C1	Operación media — carga moderada, calibración reciente	alto	~0.27
C2	Operación intensa — alta temperatura, muchos errores	medio	~0.27
C3	Sobrecarga / desgaste — altos ciclos, fallos frecuentes	medio	~0.24

Los clusters no tienen etiqueta de referencia (ground truth): su interpretación surge de observar los valores medios de cada feature por grupo.

Métricas de calidad: - Silhouette global: **0.2659** - Davies-Bouldin: **1.229** - Calinski-Harabasz: **246.6** - PCA varianza explicada: PC1=41.6%, PC2=21.8%, PC3=16.0% (total 79.4%)

2.5 Visualizaciones




Figura 1: Método del Codo

Método del Codo y Silhouette (selección de K) Esta gráfica responde la pregunta central: ¿cuántos perfiles de operación distintos existen en los datos del exoesqueleto? El eje X recorre $K \in [2, 9]$ y el eje Y muestra la inercia (WCSS), que decrece monótonamente. El “codo” — el punto donde la caída de inercia se aplana — sugiere $K = 4$ como punto de quiebre natural. Que el silhouette sea relativamente bajo en todos los valores (~ 0.27) es informativo por sí mismo: los datos de telemetría real no forman grupos perfectamente separados porque los actuadores transitan continuamente entre estados de carga, y no existe un umbral brusco entre “operación normal” y “sobrecarga”. Esto distingue el análisis de datos reales del de datos sintéticos.




Figura 2: PCA 3D Scatter

PCA 3D — Proyección de Clusters Las 9 features se proyectan en las 3 primeras componentes principales (PC1=41.6%, PC2=21.8%, PC3=16.0%), que en conjunto

retienen el 79.4% de la varianza total. Cada punto es una medición diaria de un actuador; el color indica el cluster asignado. Esta proyección permite verificar que los 4 clusters tienen cierta separación espacial en el espacio reducido, aunque los bordes entre clusters son difusos — consistente con el silhouette bajo. PC1 captura principalmente la varianza de `tiempo_uso_acumulado_h` y `ciclos_activacion_M`; PC2 recoge la señal térmica (`temp_operacional_promedio_C`, `temp_maxima_alcanzada_C`). Un cluster de color distinto y alejado del centro representa el perfil de sobrecarga extrema.




Figura 3: Estadísticas Clusters

Estadísticas por Cluster Esta gráfica convierte los clusters matemáticos en perfiles operacionales interpretables. Cada panel muestra la distribución de una feature clave desglosada por cluster (C0–C3). El patrón que permite interpretar cada grupo: C0 tiene bajos valores en casi todas las variables — operación liviana y reciente; C2 muestra temperaturas y logs de error significativamente más altos — operación bajo estrés; C3 concentra los actuadores con más horas acumuladas y mayor número de reparaciones — componentes al final de su ciclo de vida. Sin esta gráfica los clusters son abstracciones numéricas; con ella cada cluster recibe un nombre operacional.

Distribución de Actuadores por Cluster Muestra cuántas mediciones diarias cayeron en cada cluster y de qué actuadores físicos provienen. Es relevante para detectar si ciertos actuadores (por ejemplo, los de cadera que soportan mayor carga) se concentran sistemáticamente en los clusters de mayor estrés. Un actuador que aparece frecuentemente en C2 o C3 es candidato prioritario para revisión técnica, incluso si sus mediciones individuales no superan umbrales de alarma.




Figura 4: Distribución Actuadores




Figura 5: Matriz Correlación

Matriz de Correlación Antes de aplicar K-Means, esta gráfica muestra la correlación lineal entre las 9 features. Correlaciones altas entre `tiempo_uso_acumulado_h` y `ciclos_activacion_M` indican que ambas features miden esencialmente lo mismo (el uso total del actuador), lo que puede inflar artificialmente el peso de esa dimensión en el clustering. Correlaciones bajas entre features térmicas y features de uso sugieren que aportan información complementaria. Esta matriz es la justificación de por qué se necesitan 9 variables en lugar de 3 o 4: cada feature aporta señal no redundante al modelo.




Figura 6: Varianza PCA

Varianza Explicada por PCA Cuantifica cuánta información se pierde al proyectar de 9 dimensiones a 3 para visualización. Con PC1+PC2+PC3 explicando el 79.4% de la varianza, la proyección 3D preserva la mayor parte de la estructura del espacio de features. El 20.6% restante (repartido entre PC4–PC9) es ruido o varianza menor que el modelo no captura en la visualización — pero sí está presente en el clustering real. Que PC1 domine con 41.6% confirma que hay una dirección principal de variación (el eje de uso/desgaste acumulado) que organiza la mayoría de los datos.

3. Metodología — Proyecto B: Robótica Sintética (Jean)

3.1 Descripción del Problema

Un sistema de mantenimiento predictivo necesita clasificar automáticamente actuadores robóticos industriales en tres categorías de intervención usando exclusivamente telemetría — sin etiquetas previas de estado. A diferencia del Proyecto A, los datos son **sintéticos y controlados**: cada actuador fue generado con un estado de degradación explícito, lo que permite calcular purity exacta y verificar que el modelo recupera la estructura diseñada.

Dataset: 120 actuadores sintéticos, 5 tipos. Split: 84 train / 36 test.

3.2 Pipeline

Dataset (120 actuadores con telemetría de sensores)

`synthesis.jl` - generación sintética por estado de degradación

`features.jl` - 10 features de desgaste + z-score ponderado

`clustering.jl` - `auto_select_k(K [2,6]) → K* = 3`

Train Test → `assign_new_flows()` con centroides de train

`reporting.jl` - `tabla_clusters` + `mapa_piezas` + evaluación

`animation.jl` - GIFs: `kmeans_convergencia`, `k_selection`, `feature_scatter`

3.3 Feature Engineering — 10 Features de Degradación

Feature	Peso	Descripción
<code>pct_vida_util</code>	2.5	Porcentaje de vida útil consumida — señal principal
<code>tasa_fallo_por_1000h</code>	2.0	Fallos acumulados por 1 000 horas
<code>drift_posicional_mm</code>	2.0	Desviación de posición respecto al nominal
<code>dias_desde_mantenimiento</code>	1.5	Días desde último mantenimiento
<code>vibracion_rms</code>	1.5	Vibración RMS (mm/s)
<code>temperatura_operacion_c</code>	1.2	Temperatura promedio en operación (°C)
<code>eficiencia_energetica</code>	1.2	Eficiencia relativa (invertida: baja = degradada)
<code>corriente_promedio_a</code>	1.0	Corriente promedio (A)

Feature	Peso	Descripción
tiempo_uso_horas	1.0	Horas acumuladas de operación
ciclos_completados	1.0	Ciclos de movimiento completados

La feature dominante es `pct_vida_util` ($\times 2.5$): un actuador que superó su vida útil diseñada requiere reemplazo independientemente de otras métricas.

3.4 Selección Automática de K

Se evaluaron K [2, 6] con criterio silhouette + elbow (segunda derivada de inercia Δ^2J).

K	Inercia	Silhouette	Elbow Δ^2J	Seleccionado
2	714.6	0.6811	—	
3	365.1	0.6718	253.30	
4	268.8	0.6599	29.28	
5	201.9	0.6383	31.20	
6	166.1	0.6546	—	

K* = 3 — coincide con la interpretación de negocio (3 niveles de intervención). El elbow es pronunciado ($\Delta^2J = 253.3$), confirmando que 3 es el punto de quiebre natural.

3.5 Resultados

Cluster	Estado	Piezas	Vida Útil Media	Fallos/1000h	Drift (mm)	Purity
C1	Mantenimiento Pro- gra- mado	21	110.8%	10.981	1.498	1.000
C2	Mantenimiento Urgen- te	34	26.4%	0.263	0.041	1.000
C3	Reemplazo	29	70.4%	3.512	0.454	1.000

Purity global: 1.000 — los 3 clusters corresponden perfectamente a los 3 estados de degradación diseñados en la síntesis. Silhouette train = 0.6718.

Evaluación en conjunto de prueba:

Cluster	Piezas Train	Estabilidad
C1 — Programado	21	0.095
C2 — Urgente	34	0.176
C3 — Reemplazo	29	0.103

3.6 Visualizaciones

K Selection

Figura 7: K Selection

Selección de K — Codo y Silhouette (Robótica Sintética) Esta animación revela el proceso de selección automática de K ejecutado por `auto_select_k()`: en cada frame se añade una barra correspondiente a un valor candidato de K, mostrando simultáneamente la inercia (WCSS) y el coeficiente de silhouette para ese K. La barra resaltada al finalizar señala $K^* = 3$, el punto donde el silhouette alcanza un máximo local y el elbow ($\Delta^2J = 253.3$) es pronunciado. Comparada con el Proyecto A, la animación muestra una curva de silhouette con un pico más nítido y valores más altos (~ 0.67 vs ~ 0.27): los datos sintéticos fueron diseñados con clusters bien separados, por lo que el algoritmo los encuentra con facilidad y alta confianza. El K elegido coincide exactamente con los 3 estados operacionales reales del problema de mantenimiento.

Convergencia KMeans

Figura 8: Convergencia KMeans

Convergencia del Algoritmo K-Means (Robótica Sintética) Esta animación muestra el proceso iterativo de Lloyd proyectado en 2 componentes principales (PCA 2D) para hacer visible lo que ocurre en el espacio de 10 features. Cada punto es un actuador; el color indica el cluster al que pertenece en esa iteración; las estrellas son los centroides actuales. Frame a frame se observa cómo los centroides se desplazan hacia el centro de masa de sus respectivos grupos y cómo algunos actuadores reasignan su cluster al cruzar la frontera de Voronoi. La convergencia es rápida — pocas iteraciones — consecuencia de la inicialización K-Means++: los centroides iniciales ya están bien distribuidos en el espacio. A diferencia del Proyecto A, los clusters en PCA 2D son visualmente compactos y separados, reflejando la estructura sintética controlada de los datos.

Feature Scatter

Figura 9: Feature Scatter

Scatter por Features Clave (Robótica Sintética) Esta animación rota entre distintos pares de features originales — `pct_vida_util`, `drift_posicional_mm` y `vibracion_rms` — coloreando cada actuador según su cluster asignado. Su propósito es

demostrar que la separación entre clusters existe directamente en el espacio de features físicas medibles, sin necesidad de reducción dimensional. Cuando los tres clusters aparecen claramente separados en los ejes de `pct_vida_util` vs `tasa_fallo`, el resultado es interpretable por un ingeniero sin álgebra lineal: los actuadores de Reemplazo tienen vida útil alta pero fallos frecuentes; los de Mantenimiento Urgente tienen vida útil baja y fallos casi nulos (piezas nuevas con historial limpio); los Programados se ubican en zona intermedia. La separabilidad lineal en el espacio original confirma que las features elegidas capturan los mecanismos reales de degradación.

4. Comparación Técnica

4.1 Núcleo Algorítmico Compartido

Ambos proyectos implementan K-Means desde cero en Julia con los mismos componentes base:

Componente	Implementación
Inicialización	K-Means++ — primer centroide aleatorio; siguientes con prob $D(x)^2$
Paso E	<code>assign_labels()</code> — distancia euclidiana al cuadrado
Paso M	<code>update_centroids()</code> — media del cluster; clusters vacíos reciben punto aleatorio
Criterio de parada	$\ (t) - (t-1) \ < \epsilon$ o maxiter fijo
Reducción visual	PCA desde cero — eigendecomposición de la matriz de covarianza

4.2 Diferencias Clave

Aspecto	Proyecto A — Exoesqueleto (Henry)	Proyecto B — Robótica Sintética (Jean)
Origen de datos	Real — sensores físicos de exoesqueleto	Sintético — generado por <code>synthesis.jl</code>
Unidad de análisis	Medición diaria de un actuador	Actuador individual (pieza física)
N muestras	663 mediciones	120 actuadores (84 train / 36 test)
Dimensión	9 features de telemetría	10 features de desgaste (con pesos)
Feature dominante	Sin pesos explícitos — todas iguales	<code>pct_vida_util</code> $\times 2.5$
K óptimo	$K^* = 4$	$K^* = 3$

Aspecto	Proyecto A — Exoesqueleto (Henry)	Proyecto B — Robótica Sintética (Jean)
Silhouette	0.2659 — separación baja (datos reales, frontera difusa)	0.6718 — separación alta (datos sintéticos, grupos bien definidos)
Purity	Sin ground truth — no calculable	1.000 (ground truth sintético disponible)
Selección de K	Silhouette + Davies-Bouldin + Calinski-Harabasz	Silhouette + elbow Δ^2J
Normalización	Z-score estándar	Z-score ponderada por feature
Interpretación clusters	Perfiles de operación inferidos post-hoc	Estados de mantenimiento conocidos a priori
Animaciones	Estáticas (PNG)	Dinámicas (GIF): convergencia, K-selection, scatter
Validación externa	No disponible	Train/test split con estabilidad por cluster

4.3 Por Qué Silhouette Difiere Tanto (0.27 vs 0.67)

Causa	Explicación
Naturaleza de los datos	Datos reales contienen ruido, outliers y transiciones graduales entre estados. Datos sintéticos tienen grupos perfectamente separados por diseño.
K correcto vs. K* elegido	En el Proyecto A, K=4 no es el máximo silhouette (K=2 tiene 0.31) — se sacrifica silhouette por granularidad operacional. En el Proyecto B, K=3 es el máximo de silhouette Y el K correcto.
Feature engineering	Los pesos explícitos en Proyecto B amplifican la separación natural entre clusters; en Proyecto A todas las features contribuyen igual y algunas son ruidosas.
Tamaño de muestra	663 mediciones incluyen actuadores en estados de transición que el modelo no puede asignar a un cluster con alta confianza.

5. Análisis Comparativo Visual

5.1 Curva de Inercia

Ambos proyectos muestran el codo característico de K-Means:

- **Proyecto A (exoesqueleto):** codo suave, difuso entre $K=3-5$. La inercia inicial es alta (2 866 en $K=2$) y cae gradualmente — estructura de datos compleja sin grupos evidentes.
- **Proyecto B (sintético):** codo pronunciado en $K=3$ ($\Delta^2J = 253.3$). La inercia cae bruscamente de $K=2$ a $K=3$ y luego se aplana — estructura limpia con 3 grupos naturales.

5.2 Ejemplo de Asignación

Proyecto A — Medición A1_Cadera_Derecha, 2024-01-01 → C0:

tiempo_uso_acumulado_h = 1868.4 (uso moderado)
 ciclos_activacion_M = 16.1 (ciclos moderados)
 fallos_temporales = 3 (algunos fallos)
 temp_operacional_C = 52.9 (temperatura normal)
 numero_logs_error = 8 (errores bajos)
 → Perfil: operación estándar, sin señales de desgaste extremo

Proyecto B — Actuador #14 → C2 (Mantenimiento Urgente):

pct_vida_util = 21.2% (pieza nueva)
 tasa_fallo = 0.263 (fallos bajos)
 drift_posicional = 0.038mm (desviación mínima)
 dias_sin_mant = 47 (mantenimiento reciente)
 → Pieza nueva que requiere intervención preventiva antes de degradarse

6. Conclusiones y Recomendación de Enfoque

6.1Cuál Es Mejor para Su Dominio

Criterio	Proyecto A — Exoesqueleto	Proyecto B — Robótica Sintética	Ganador
Silhouette	0.265	0.672	B
Separación visual clusters (PCA)	Difusa	Compacta	B
Purity con ground truth	N/A	1.000	B
Aplicabilidad a datos reales	Sí	Solo sintético	A

Criterio	Proyecto A — Exoesqueleto	Proyecto B — Robótica Sintética	Ganador
Interpretación post-hoc	Necesaria	Inmediata (K=estados)	B
Riqueza de métricas de selección de K	Alta (silhouette+DB+CH)	Media (silhouette+elbow)	A
Soporte para datos continuos/ruidosos	Sí	No diseñado para eso	A

6.2 Recomendación

Para análisis de datos reales de sensores (exoesqueleto, IoT, PLCs): el enfoque del Proyecto A es el correcto. Los datos reales no tienen ground truth, los clusters son difusos, y usar múltiples métricas de selección de K (silhouette + DB + CH) es necesario porque ninguna métrica única es concluyente. El silhouette bajo (~ 0.27) no es un fallo del modelo — es una propiedad honesta de los datos.

Para diseño y validación de pipelines de clustering: el Proyecto B es superior como framework de referencia. La generación sintética controlada permite verificar que el algoritmo recupera exactamente la estructura diseñada (purity=1.0), lo que sirve para validar la implementación antes de aplicarla a datos reales. El pipeline modular (`synthesis.jl`, `features.jl`, `clustering.jl`, `reporting.jl`, `animation.jl`) es reutilizable para cualquier dominio con 3 estados discretos bien separados.

Como base algorítmica: ambos usan el mismo motor K-Means++ — cualquiera sirve de template para nuevas aplicaciones en Julia con selección automática de K y validación cuantitativa.

6.3 Mejoras Futuras Compartidas

Mejora	Aplica a
Reemplazar K-Means por DBSCAN para clusters no esféricos	A (prioritario — datos reales ruidosos)
Usar t-SNE o UMAP en lugar de PCA para visualización	A y B
Validación cruzada k-fold en lugar de un único split	B
Agregar ground truth parcial al exoesqueleto (etiquetado manual de sesiones)	A

Mejora	Aplica a
Conectar Proyecto B con datos reales de SCADA/CMMS	B (prioridad)
Análisis temporal de deriva de clusters (concept drift)	A (prioridad)

7. Referencias de Archivos

priv-Redes-Complejas-Grupo/

Kmeans_Robot_Henry/

- exoesqueleto_actuadores.csv ← Proyecto A: Exoesqueleto (Henry)
- exoesqueleto_con_clusters.csv - dataset original
- analisis_kmeans.json - mediciones con cluster asignado
- 01_metodo_codo.png - métricas K-selection y centroides PCA
- 02_pca_3d_scatter.png - curva inercia vs K
- 03_estadisticas_clusters.png - proyección PCA 3D con clusters
- 04_distribucion_actuadores.png - distribución de features por cluster
- 05_matriz_correlacion.png - mediciones por actuador y cluster
- 06_varianza_pca.png - correlación entre features
- reporte_exoesqueleto_kmeans.md - varianza explicada por componente PCA
- reporte completo del análisis

Kmeans_Robot_Jean/

Robotica_kmeans_sintetico/

src/

- synthesis.jl ← Proyecto B: Robótica Sintética (Jean)
- features.jl - pipeline modular Julia
- clustering.jl - generación del dataset sintético
- reporting.jl - 10 features + z-score ponderado
- animation.jl - K-Means++, auto_select_k, silhouette
- tablas y métricas
- GIFs de convergencia y selección de K

results/

- animations/ - k_selection.gif, kmeans_convergencia.gif, feature_sc...
- raw/ - piezas_completo.csv, piezas_train.csv, piezas_test.c...
- report/ - tabla_clusters.csv, mapa_piezas.csv, test_evaluacion...
- reporte.md - reporte generado por el pipeline

Kmeans_Comparacion/

comparacion.md

← este documento

Documento generado el 2026-06-03. Universidad de Cuenca — DEET.