

CLUSTERING DE ACTUADORES ROBÓTICOS

K-Means *vs* Louvain

Dos paradigmas, los mismos datos: ¿llegan a la misma estructura?

MÉTODO A · PARTICIONAL K-Means Parte el espacio por distancia a centroides	MÉTODO B · GRAFO Louvain Descubre comunidades maximizando modularidad
--	---

01 - CONTEXTO

Clasificar actuadores por estado

Un inventario de actuadores robóticos debe agruparse, sin etiquetas previas, en tres niveles de intervención de mantenimiento.



02 — DATOS

120 actuadores, 10 features

120

ACTUADORES SINTÉTICOS

5

TIPOS DE ACTUADOR

10

FEATURES DE DEGRADACIÓN

3

ESTADOS (GROUND TRUTH)

SPLIT ESTRATIFICADO

84 · Train (70%)


36 · Test

Z-score ponderado — peso = fuerza de la señal

×2.5	pct_vida_util	×2.0	tasa_fallo / 1000h
×2.0	drift_posicional_mm	×1.5	días_sin_mant.
×1.5	vibracion_rms	×1.2	temperatura_op_c
×1.2	eficiencia_energ.	×1.0	corriente_prom_a
×1.0	tiempo_uso_horas	×1.0	ciclos_completados

03 — CÓMO FUNCIONA K-MEANS

Particionar por distancia



01 Inicializar (K-Means++)

Se colocan K centroides bien separados. Aquí $K = 3$.

02 Asignar (paso E)

Cada pieza se une al centroide **más cercano** en distancia euclidiana.

03 Actualizar (paso M)


Cada centroide se mueve a la **media** de su grupo.

04 Repetir hasta converger


Minimiza la inercia $\sum \|x - \mu\|^2$. Clusters esféricos (Voronoi).

04 — SELECCIÓN AUTOMÁTICA DE K

El codo apunta a $K=3$




El codo es **pronunciado** ($\Delta^2 J = 253.3$) y el silhouette se mantiene alto: K-Means elige **3**, igual que los 3 estados del negocio.



K = 2	sil 0.681 · iner 714.6
K = 3 ◀	sil 0.672 · $\Delta^2 J$ 253.3
K = 4	sil 0.660 · iner 268.8
K = 5	sil 0.638 · iner 201.9
K = 6	sil 0.655 · iner 166.1

05 – CÓMO FUNCIONA LOUVAIN

De features a comunidades




Louvain mueve nodos entre comunidades para maximizar la modularidad Q:


$$Q = (1/2m) \cdot \sum [w_{ij} - k_i k_j / 2m] \cdot \delta(c_i, c_j)$$

05 - COMUNIDADES DETECTADAS

3 comunidades, $Q = 0.555$




El número de comunidades **no se fijó**: emergió de maximizar Q . Louvain encuentra exactamente **3** grupos.



06 — RESULTADO CLAVE

Dos caminos, *una misma* estructura



*K-Means (geométrico) y Louvain (grafo) **no comparten nada** en su formulación — y aun así agrupan los actuadores de forma idéntica.*

1.000	1.000	1.000
ARI	NMI	PURITY

Que dos métodos sin nada en común coincidan es evidencia fuerte de que los **3 estados de mantenimiento son estructura real** del dataset — no un artefacto de un algoritmo.

07 — CUÁNDO USAR CADA UNO

Dos herramientas, dos lógicas

ASPECTO	K-Means	Louvain
PARADIGMA	Particional (geométrico)	Comunidades en grafo
¿REQUIERE K?	Sí — auto vía silhouette	No — K emerge de Q
OPTIMIZA	Inercia (WCSS)	Modularidad Q
FORMA DE CLUSTERS	Esférica (Voronoi)	Arbitraria (densidad)
ENTRADA	Matriz de features	Grafo de similitud k-NN
SENSIBILIDAD	A inicialización y a K	Al parámetro k del grafo

08 — CONCLUSIONES

Convergencia de *paradigmas*

01 Misma estructura

K-Means y Louvain, sin nada en común, recuperan la **misma partición** (ARI = NMI = 1.000). Los 3 estados son estructura real.

03 Pipeline unificado

Un solo `run_pipeline.jl` ejecuta síntesis, features, K-Means, grafo k-NN, Louvain, comparación y reportes. Determinista.

02 Louvain valida K

K-Means necesita fijar K; Louvain lo descubre. Que halle 3 comunidades **confirma de forma independiente** el $K^* = 3$.

04 Limitación honesta

Louvain depende de k. Aquí $k \approx 30\%$ de n es robusto; en datos reales habría que **validar k por estabilidad**.